Emergent Communication：AI エージェントは「言語」を発明するのか？

はじめに

2016 年ごろ、ある種の不気味なニュースが話題になった。Facebook AI Research（現 Meta AI）が開発した AI エージェント同士が交渉タスクをこなすうちに、人間には理解できない独自の「言語」を勝手に作り出した、というものだ。

この現象は研究者たちにとって驚きではなかった。むしろ、彼らはそれを意図的に起こそうとしていた。複数の AI エージェントに協力タスクを与え、通信チャネルだけを用意して、あとは勝手にやらせる。すると、エージェントたちは報酬を最大化するために自発的にコミュニケーション・プロトコルを「発明」する。

この研究分野は **Emergent Communication（創発的コミュニケーション）** と呼ばれる。本記事では、この分野の成り立ち、主要論文の時系列、キーパーソン、各論文の目的、研究者たち自身が語る実用性、そして彼らがまだ言及していない実用可能性について整理する。

研究領域名

この分野の正式な呼称は **Emergent Communication**（略称: EC）である。隣接する呼び方として **Language Emergence**（言語創発）、**Emergent Language**（創発言語）も使われる。

より広い文脈では、マルチエージェント強化学習（MARL: Multi-Agent Reinforcement Learning）の一分野に位置づけられ、計算言語学・進化言語学・ゲーム理論とも交差する学際的な領域だ。ICLR では 2018 年から毎年 "Emergent Communication Workshop" が開催されており、独立したコミュニティとして成熟しつつある。

キーパーソン

この分野を牽引してきた主要な研究者を挙げる。

Angeliki Lazaridou（Google DeepMind）は、この分野の中心人物といってよい。2017 年の参照ゲーム論文で分野を切り拓き、2020 年には包括的なサーベイ論文を執筆。2022 年には EMNLP でチュートリアルも行っている。

Marco Baroni（Pompeu Fabra 大学 / 元 Facebook AI Research）は、Lazaridou との共同研究を多数行い、言語学的観点からの分析に強みを持つ。サーベイ論文の共著者でもある。

Jakob Foerster（オックスフォード大学 / 元 Facebook AI Research）は、深層強化学習によるエージェント間通信の学習という枚組みを最初に提案した人物の一人。

Satwik Kottur（Carnegie Mellon 大学 → Meta）は、「自然言語は自然には創発しない」という重要な否定的結果を示した。

Igor Mordatch（OpenAI → Google DeepMind）は、物理的に身体化されたエージェントにおける構成的言語の創発を示した。

Dhruv Batra（Georgia Tech / Meta AI）は、Kottur らとの共同研究を通じて、構成性と解釈可能性の条件を体系的に調査した。

主要論文の時系列と各論文の目的

以下、分野の発展を年代順に追う。

2016 年：出発点

Foerster, Assael, de Freitas & Whiteson. *"Learning to Communicate with Deep Multi-Agent Reinforcement Learning." NeurIPS 2016.*

この論文が深層学習時代の Emergent Communication 研究の起点となった。RIAL（Reinforced Inter-Agent Learning）と DIAL（Differentiable Inter-Agent Learning）という 2 つの手法を提案し、エージェントが事前に設計されたプロトコルなしにゼロからコミュニケーションを学習できることを示した。

同時期に **Sukhbaatar, Fergus et al.** *"Learning Multiagent Communication with Backpropagation." NeurIPS 2016.* が発表され、CommNet と呼ばれる連続的な通信チャネルによるアプローチも提案されている。

2017 年：爆発的展開

2017 年は、この分野にとって最も重要な年だった。

Lazaridou, Peysakhovich & Baroni. *"Multi-Agent Cooperation and the Emergence of (Natural) Language." ICLR 2017.*

Lewis のシグナリングゲームに基づく参照ゲームにおいて、送信エージェントと受信エージェントが画像ペアについてコミュニケーションする設定を提案。エージェントが任意の語彙からゼロベースで「単語の意味」を学習できることを示した。目的は「エージェント間の協力的コミュニケーションから、人間の意味論に近い言語が創発しうるか」の検証だった。

Kottur, Moura, Lee & Batra. *"Natural Language Does Not Emerge 'Naturally' in Multi-Agent Dialog." EMNLP 2017 (Best Short Paper).*

Lazaridou らの楽観的な結果に対して、重要な反証を提示した論文である。エージェントが発明した言語はタスク報酬をほぼ完璧に達成するものの、人間にとっては解釈不能かつ構成的でもないことを体系的に示した。しかし同時に、通信の制約を増やすことで、より構成的で人間に近い言語へ誘導できることも明らかにした。

Mordatch & Abbeel. *"Emergence of Grounded Compositional Language in Multi-Agent Populations." arXiv 2017 / AAAI 2018.*

物理的に身体化されたエージェントが 2D 環境で目標地点に移動するなどの協力タスクを行う設定を採用。語彙と構文を備えた基本的な構成的言語が創発することを示した。目的は「物理的に接地された環境で、構成的な言語が自発的に出現しうるか」の実証だった。

Havrylov & Titov. *"Emergence of Language with Multi-agent Games: Learning to Communicate with Sequences of Symbols." NeurIPS 2017.*

参照ゲームにおいて、REINFORCE と Gumbel-softmax による微分可能な緩和の 2 つのアプローチを比較。後者のほうが収束が速く、より効果的なプロトコルを生成することを発見した。

2018 年：多様化

Evtimova, Drozdov, Kiela & Cho. *"Emergent Communication in a Multi-Modal, Multi-Step Referential Game." ICLR 2018.*

視覺情報のみを持つ送信エージェントとテキスト情報のみを持つ受信エージェントという、異なるモダリティを持つエージェント間での複数ステップ双方向通信の創発を調査した。

Cao, Lazaridou, Lanctot, Leibo, Tuyls & Clark. *"Emergent Communication through Negotiation." ICLR 2018.*

半協力的な交渉ゲームにおけるマルチターン通信の創発を研究。自己利益と協力のバランスの中でどのような通信プロトコルが出現するかを分析した。

2019〜2020 年：構成性の深掘りとサーベイ

Chaabouni, Kharitonov, Bouchacourt, Dupoux & Baroni. *"Compositionality and Generalization in Emergent Languages." ACL 2020.*

創発言語の構成性と汎化能力の関係を深く掘り下げた。構成性は単純な汎化圧力からは生じないが、一度構成的な言語が偶然生まれると、それが生き残りやすいことを示した。

Lazaridou & Baroni. *"Emergent Multi-Agent Communication in the Deep Learning Era." arXiv 2020.*

この分野の包括的なサーベイ論文。科学的観点（人間の言語進化の理解）と応用的観点（インタラクティブな AI の構築）の両面から、代表的な研究を整理した。

2022 年以降：スケーリングと LLM との統合

Chaabouni et al. *"Emergent Communication at Scale." ICLR 2022.*

従来の小規模な参照ゲームから、より大規模で現実的な設定へのスケーリングを試みた研究。

Li et al. *"Language Grounded Multi-agent Reinforcement Learning with Human-interpretable Communication." NeurIPS 2024.*

LLM をエージェントとして身体化させ、その合成データを使って MARL エージェントの通信を人間の自然言語に「接地」させるアプローチ。創発言語を後から解読するのではなく、最初から人間に解釈可能な形で学ばせるという方向転換を示している。

論文執筆者たちが語る実用性

研究者たち自身は、この分野の実用性について主に以下の観点を挙げている。

人間の言語進化の理解。 Lazaridou & Baroni (2020) のサーベイでは、深層エージェントの言語創発を研究することで人間の言語がどのように進化したかの手がかりが得られると述べている。

マルチエージェント協調の効率化。 ほぼすべての論文が、エージェント間通信がタスク成績を向上させることを報告している。

人間−AI チームワーク。 Kottur らが示した「解釈可能性の条件」や、Li et al. (2024) が示した「言語接地による未知のチームメイトへのゼロショット汎化」は、人間と AI が混成チームとして働く場面への応用を強く意識している。

ロバストな AI 通信プロトコルの設計。 Mordatch & Abbeel は、エージェントが環境に接地された通信を学ぶことで、手作業でプロトコルを設計するよりもタスクに適応的で効率的な通信が実現しうると主張している。

論文執筆者が言及していない実用可能性

ここからは、既存の論文群では直接的に議論されていないが、この研究分野の成果から導き出せる実用可能性について考察する。

1. AI システムの内部通信の監査・安全性検証

大規模 AI システムが複数のサブモジュール間で内部的に情報をやりとりする場合、そのメッセージが人間に解釈不能であることはセキュリティ上のリスクとなる。EC 研究で蓄積された「創発言語の解釈可能性を高める技法」は、AI システムの内部通信を人間が監査可能にするための設計原則として応用できる可能性がある。これは AI アライメント研究と直結するテーマだ。

2. 異文化・異言語間コミュニケーションの補助

エージェントが異なるモダリティや異なる学習履歴を持ちながらも共通のプロトコルを発達させるメカニズムは、人間同士が共通言語を持たない状況でのコミュニケーション支援に応用できるかもしれない。

3. IoT デバイス・ロボット群のアドホック協調

工場のロボット群や IoT センサーネットワークにおいて、事前にプロトコルを設計せずに、デバイスが自律的に通信プロトコルを学習する仕組みは、デバイスの追加・交換・異機種混在に対して柔軟に対応できる。

4. ゲーム AI における NPC の自律的コミュニケーション

ゲーム内の NPC がプレイヤーの行動に応じて互いにコミュニケーションをとり、協力・競争する振る舞いを自律的に発展させることができれば、よりリアルで予測不能なゲーム体験を提供できる。

5. 分散型金融・自律エージェント経済における交渉プロトコル

Cao ら (2018) の交渉ゲームにおける創発的コミュニケーションの研究は、分散型の自律エージェントが市場で取引を行う場面に拡張できる。DeFi やサプライチェーン最適化の文脈で検討に値する。

6. 言語が生まれる「以前」の知能の研究

この分野の研究は、言語を持たないエージェントが言語的なものを生み出す瞬間を再現している。発達心理学・動物行動学との学際的な橋渡しとして、まだ十分に活用されていない。

まとめ

Emergent Communication 研究は、2016 年の Foerster らの論文を起点に、わずか 10 年足らずで一つの研究コミュニティを形成するまでに成長した。その核心的な問いは「AI エージェントは、人間がそうであったように、協力の必要性から自発的に言語を生み出すのか？」である。

答えは「Yes、ただし条件付き」だ。エージェントは確かに効果的な通信プロトコルを発明するが、それが人間にとって解釈可能で構成的な「言語」であるためには、語彙の制約、環境の接地、世代間の伝達といった追加的な圧力が必要である。

2024 年の Li et al.に見られるように、この分野は現在、LLM との統合という新しいフェーズに入りつつある。「創発した後に解読する」から「最初から人間に分かる形で創発させる」へ。AI エージェントの言語が人間の言語と接続される日は、思ったよりも近いのかもしれない。

付録：関連研究 — LangGround

論文情報

- **タイトル:** Language Grounded Multi-agent Reinforcement Learning with Human-interpretable Communication
- **著者:** Huao Li, Hossein Nourkhiz Mahjoub, Behdad Chalaki, Vaishnav Tadiparthi, Kwonjoon Lee, Ehsan Moradi Pari, Charles Michael Lewis, Katia P. Sycara
- **所属:** University of Pittsburgh / Honda Research Institute USA / Carnegie Mellon University
- **会議:** NeurIPS 2024（ポスター発表）
- **arXiv:** 2409.17348

論文の概要

本論文が提案する **LangGround** は、MARL エージェントのコミュニケーション空間を人間の自然言語の埋め込み空間に整合させるパイプラインである。

ステップ 1：LLM による合成データ生成。 LLM をチームワークタスクの環境内に「身体化」させ、複数の LLM エージェント同士にタスクを遂行させる。その発話と対応する環境状態のペアを合成データセットとして収集する。

ステップ 2：言語接地付き MARL の学習。 エージェントが出力するコミュニケーションベクトルが自然言語メッセージの埋め込みと近くなるように正則化を加える。

ステップ 3：アドホックチームワークでの評価。 学習済みの LangGround エージェントを未知のチームメイトと組ませ、翻訳モジュールを介して即席で協力するタスクを遂行する。

主要な結果

第一に、**言語接地はタスク性能を犠牲にしない**。従来の MARL 手法と同等以上のタスク成績を達成した。

第二に、**言語接地はコミュニケーションの創発を加速する**。制約が学習の方向性を絞り込むことで、より早く有意味な通信プロトコルに到達する。

第三に、**ゼロショットのアドホック汎化が可能になる**。未知のチームメイトや訓練時に見たことのないタスク状態に対しても、学習した通信プロトコルがそのまま機能する。

参考文献

1. Foerster, J. N., Assael, Y. M., de Freitas, N., & Whiteson, S. (2016). Learning to Communicate with Deep Multi-Agent Reinforcement Learning. NeurIPS 2016.
2. Sukhbaatar, S., Fergus, R., et al. (2016). Learning Multiagent Communication with Backpropagation. NeurIPS 2016.
3. Lazaridou, A., Peysakhovich, A., & Baroni, M. (2017). Multi-Agent Cooperation and the Emergence of (Natural) Language. ICLR 2017.
4. Kottur, S., Moura, J. M. F., Lee, S., & Batra, D. (2017). Natural Language Does Not Emerge 'Naturally' in Multi-Agent Dialog. EMNLP 2017.
5. Mordatch, I. & Abbeel, P. (2018). Emergence of Grounded Compositional Language in Multi-Agent Populations. AAAI 2018.
6. Havrylov, S. & Titov, I. (2017). Emergence of Language with Multi-agent Games. NeurIPS 2017.
7. Evtimova, K., Drozdov, A., Kiela, D., & Cho, K. (2018). Emergent Communication in a Multi-Modal, Multi-Step Referential Game. ICLR 2018.
8. Cao, K., Lazaridou, A., Lanctot, M., Leibo, J. Z., Tuyls, K., & Clark, S. (2018). Emergent Communication

through Negotiation. ICLR 2018.
9. Chaabouni, R., Kharitonov, E., Bouchacourt, D., Dupoux, E., & Baroni, M. (2020). Compositionality and Generalization in Emergent Languages. ACL 2020.
10. Lazaridou, A. & Baroni, M. (2020). Emergent Multi-Agent Communication in the Deep Learning Era. arXiv:2006.02419.
11. Chaabouni, R. et al. (2022). Emergent Communication at Scale. ICLR 2022.
12. Li, H. et al. (2024). Language Grounded Multi-agent Reinforcement Learning with Human-interpretable Communication. NeurIPS 2024.